

2026년 개인주제탐구발표대회 보고서

선박 사고 상황에서의 개인별 생존률 예측

2026. 9. 3.

과 정 명	AI
소속 학교	대전한밭초등학교
성 명	박준하

대전교육정보원정보영재교육원

목 차

I. 탐구(연구)의 필요성 및 목적	1
1. 탐구(연구)의 필요성	1
2. 연구 목적	1
II. 이론적 배경	2
1. 선행 연구	2
2. 주요 분석 개념	2
III. 탐구(연구) 방법 및 과정	3
1. 연구 자료 및 변수	3
2. 데이터 전처리 및 상관관계 분석	4
3. 생존률 결정 후보 factor 검증	5
4. 로지스틱 회귀모델 제작	6
IV. 연구 결과	7
V. 결론 및 제언	8
※ 참고문헌	—

I. 탐구(연구)의 필요성 및 목적

1. 탐구(연구)의 필요성

가. 선박 사고의 위험성

선박 사고는 자동차 사고보다 전체 사망자 규모가 작을 수 있지만, 한 번 발생하면 많은 사람이 동시에 위험해져 대형 참사로 이어질 가능성이 있다. 작품설명서에서는 국내 선박사고 사망자를 연간 약 160명, 자동차 사고 사망자를 약 2,900명으로 제시하였다.

선박 사고가 특히 위험한 이유는 침수·전복 시 탈출로가 사라질 수 있고, 익수와 저체온증으로 생존 시간이 짧아지며, 원거리·야간·악천후에는 구조가 늦어질 수 있기 때문이다. 또한 좁은 공간에 많은 사람이 밀집해 있고 화재·연기·패닉이 동시에 생길 수 있다.



그림 1. 작품설명서에 제시된 선박 사고의 대형 참사 위험 요인

나. 개인별 생존률 예측의 필요성

사고 순간에는 구조 인력과 시간이 제한될 수 있다. 과거 자료를 이용하여 어떤 조건의 사람이 상대적으로 더 위험했는지를 알 수 있다면 구조계획을 세우는 데 참고할 수 있다. 이에 성별, 나이, 승무원 여부, 동승객 여부와 생존 여부의 관계를 분석하고 개인별 생존 확률을 계산하는 AI 모델을 만들고자 하였다.

2. 연구 목적

- 18개 선박사고, 약 15,000명의 개인 자료에서 생존 여부와 관련된 factor를 찾는다.
- 상관관계 매트릭스와 집단별 생존률 비교로 후보 factor를 검증한다.
- 검증된 factor를 사용하여 개인별 생존 확률을 예측하는 로지스틱 회귀모델을 제작한다.

II. 이론적 배경

1. 선행 연구

가. “Women and Children First”

선박 사고에는 여성과 어린이를 먼저 대피시킨다는 “Women and Children First(WCF)” 규범이 널리 알려져 있다. 이 규범만 생각하면 여성이나 어린이의 생존률이 더 높을 것으로 예상할 수 있다. 그러나 실제 사고에서는 침몰 속도, 구조 명령, 승객 위치 등 많은 조건이 동시에 작용하므로 실제 자료로 확인할 필요가 있다.

나. Elinder와 Erixson의 자료

작품설명서는 Elinder와 Erixson의 2012년 논문 “Gender, social norms, and survival in maritime disasters”가 정리한 데이터를 사용하였다. 이 자료는 약 300년에 걸친 18개 선박사고와 15,000명 이상의 개인을 포함하여 한 사고만이 아니라 여러 사고를 비교할 수 있다.



그림 2. Elinder & Erixson(2012) 논문

본 탐구는 이 자료를 AI 분석 관점에서 다시 살펴보고, 개인 정보를 이용해 생존 확률을 계산하는 모델까지 만드는 데 초점을 두었다.

2. 주요 분석 개념

가. 상관관계

상관계수는 두 변수가 함께 변하는 정도를 $-1 \sim 1$ 사이의 값으로 나타낸다. 1에 가까우면 같은 방향, -1 에 가까우면 반대 방향의 관계가 강하고, 0에 가까우면 단순한 선형 관계가 약하다. 다만 상관관계가 곧 원인이라는 뜻은 아니다.

나. 로지스틱 회귀

로지스틱 회귀는 결과가 두 종류로 나뉘는 문제에서 각 결과의 확률을 예측하는 머신러닝 방법이다. 본 탐구에서는 여러 개인 정보를 동시에 입력하여 각 사람의

생존 확률을 계산하는 데 사용하였다.

Ⅲ. 탐구(연구) 방법 및 과정

1. 연구 자료 및 변수

가. 데이터 불러오기

Python의 pandas로 CSV 파일을 불러온 뒤 앞부분을 출력하여 열 이름과 값이 정상적으로 읽혔는지 확인하였다. 자료에는 HMS Birkenhead를 포함한 18개 선박사고와 각 사고의 개인 정보가 들어 있다.



그림 3. pandas로 불러온 데이터의 일부

나. 주요 변수

상관관계 매트릭스에서는 사고 수준과 개인 수준의 여러 수치형 변수를 함께 확인하였다. 최종 예측모델에서는 작품설명서의 코드에 따라 Gender, Age, Crew, Companionship을 입력값으로 사용하고 Survival을 목표값으로 사용하였다.

구분	주요 변수	의미
사고 수준	Year, WCF, Quick, 승선 규모, Ship size, Length of voyage	사고의 시기·특성과 전체 규모
개인 수준	Gender, Age, Child, Crew, Companionship	성별, 나이, 어린이 여부, 승무원 여부, 동승객 여부
예측 목표	Survival	개인의 생존 여부
최종 모델 입력	Gender, Age, Crew, Companionship	개인별 생존 확률 계산에 사용

표 1. 분석에 사용한 변수 구성

다. 전체 절차

연구는 ① 데이터 로딩과 정리, ② 상관관계 매트릭스 생성, ③ 후보 factor의 생존률 비교, ④ 로지스틱 회귀모델 제작의 네 단계로 진행하였다.

Ⅲ. 탐구(연구) 방법 및 과정(계속)

2. 데이터 전처리 및 상관관계 분석

가. 데이터 전처리

모델 코드에서는 빈 문자열을 결측값(NaN)으로 바꾸고 Gender, Age, Crew, Companionship, Survival을 숫자형으로 변환하였다. Age의 결측값은 중앙값, Gender·Child·Crew·Companionship의 결측값은 최빈값으로 채웠고, Survival이 없는 행은 제거하였다.

나. 상관관계 매트릭스

숫자형 변수에 대해 Pearson 상관계수를 계산하고 seaborn heatmap으로 표시하였다. 각 칸의 숫자가 두 변수 사이의 상관계수이며, 빨간색은 양의 관계, 파란색은 음의 관계를 뜻한다.





그림 4. 작품설명서의 상관관계 매트릭스

Survival과의 상관계수는 최종 개인 factor 중 Crew가 약 +0.14로 가장 컸고, Gender와 Companionship은 약 -0.07, Age는 약 -0.06이었다. 값의 절댓값이 크지 않아 한 factor만으로 생존을 설명하기 어렵다고 판단하고 다음 단계에서 집단별 생존률을 비교한 뒤 여러 factor를 함께 사용하는 모델을 제작하였다.


Ⅲ. 탐구(연구) 방법 및 과정(계속)

3. 생존률 결정 후보 factor들의 검증


작품설명서에서는 성별, 승무원 여부, 동승객 여부에 따라 집단을 나누어 실제 생존률을 비교하였다. 나이는 상관행렬에서 약한 음의 상관을 보였고 최종 모델의 입력 factor로 포함되었다.



(가) 성별



(나) 승무원 여부



(다) 동승객 여부

Age

Age와 Survival의 상관계수는 약 -0.06 이었다. 별도 연령대 그래프는 작품설명서에 제시되지 않았지만 Age는 최종 예측모델에 포함되었다.

그림 5. 후보 factor별 생존률 비교

가. 성별 결과

남성 생존률은 약 39%, 여성은 약 32%로 나타났다. 이는 WCF만으로 “여성 생존률이 더 높을 것”이라고 단순하게 예측하기 어렵다는 결과이다.

나. 승무원 여부 결과

승객은 약 33%, 승무원은 약 49%로 승무원의 생존률이 더 높았다. 상관행렬에서도 Crew가 최종 개인 factor 중 가장 큰 양의 상관을 보였다.

다. 동승객 여부 결과

동승객이 없는 집단은 약 53%, 동승객이 있는 집단은 약 46%였다. 다만 이 차이만으로

동승객의 존재가 생존을 직접 낮춘다고 단정할 수는 없다.

Ⅲ. 탐구(연구) 방법 및 과정(계속)

4. 로지스틱 회귀모델 제작

최종 모델에서는 Gender, Age, Crew, Companionship을 입력 변수로, Survival을 예측 목표로 사용하였다. 여러 factor를 동시에 사용하면 한 factor만 볼 때보다 개인별 생존 가능성을 종합적으로 계산할 수 있다.

단계	방법
1	빈칸 처리 및 숫자형 변환, 결측값 보완
2	train_test_split: 80% 학습 / 20% 평가, stratify=y
3	StandardScaler로 입력값 표준화
4	LogisticRegression으로 학습
5	accuracy_score로 평가
6	predict_proba로 개인 생존 확률 출력

표 2. 최종 모델 제작 절차

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score

train = pd.read_csv('선박 최종 데이터.csv')
features = ['Gender', 'Age', 'Crew', 'Companionship']
target = 'Survival'
train = train.replace('.', np.nan)
for col in features + [target]:
    train[col] = pd.to_numeric(train[col], errors='coerce')
train['Age'] = train['Age'].fillna(train['Age'].median())
for col in ['Gender', 'Child', 'Crew', 'Companionship']:
    train[col] = train[col].fillna(train[col].mode()[0])
train = train.dropna(subset=[target])
X = train[features]
y = train[target].astype(int)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)
model = LogisticRegression()
model.fit(X_train, y_train)
y_pred = model.predict(X_test)
accuracy = accuracy_score(y_test, y_pred)
print("모델 정확도:", accuracy)
```

그림 6. 로지스틱 회귀모델 학습 코드

학습자료를 기준으로 표준화를 한 뒤 평가자료에는 같은 변환을 적용하였다. 모델이 학습되면 predict_proba를 이용해 0~1 사이의 생존 확률을 얻을 수 있다. 따라서 최종 결과는 단순한 생존/사망 분류뿐 아니라 “이 승객의 생존 가능성이 몇 %인가?”를 제시할 수 있다.

IV. 연구 결과

1. factor 분석 결과

개인 factor와 Survival의 상관계수는 Crew 약 +0.14, Gender 약 -0.07, Companionship 약 -0.07, Age 약 -0.06이었다. Crew의 관계가 가장 두드러졌지만 네 값 모두 절댓값이 크지 않아 여러 정보를 함께 사용해야 함을 알 수 있었다.

Factor	상관계수	집단별 결과
Gender	약 -0.07	남성 약 39%, 여성 약 32%
Age	약 -0.06	약한 음의 상관
Crew	약 +0.14	승객 약 33%, 승무원 약 49%
Companionship	약 -0.07	없음 약 53%, 있음 약 46%

표 3. 최종 모델에 사용한 개인 factor 결과 요약

2. 모델 정확도

작품설명서의 실행 결과에서 평가자료에 대한 정확도는 0.6191108161911082, 즉 약 61.9%였다. 네 가지 개인 정보만으로도 어느 정도 예측은 가능했지만, 실제 의사결정에 바로 사용할 정도로 매우 높은 정확도는 아니므로 추가 변수와 검증이 필요하다.

3. 개인별 확률 출력

새로운 사람의 정보를 입력한 예시에서는 predict_proba를 이용해 생존 확률 68.63%가 출력되었다. 즉, 본 탐구는 “승객 정보를 입력하면 개인별 생존확률을 계산한다”는 목표를 실제 코드로 구현하였다.

```
new_person = pd.DataFrame({
    'Gender': [0],
    'Age': [1],
    'Child': [0],
    'Crew': [1],
    'Companionship': [1]
})

new_person_scaled = scaler.transform(new_person)

probability = model.predict_proba(new_person_scaled)[0][1]

print(f"생존 확률: {probability * 100:.2f}%")

... 생존 확률: 68.63%
```

그림 7. 예시 승객에 대해 생존 확률 68.63%를 출력한 결과

결과를 종합하면, 개별 factor의 단순 상관은 약했지만 여러 factor를 함께 사용한 로지스틱 회귀모델을 통해 개인별 확률을 계산할 수 있었다. 동시에 61.9%의 정확도는 사고 상황을 설명하는 추가 정보가 중요하다는 점도 보여준다.

V. 결론 및 제언

1. 결론

본 탐구에서는 18개 선박사고와 약 15,000명의 개인 자료를 이용하여 생존 여부와 관련된 factor를 분석하고, Gender, Age, Crew, Companionship을 이용해 개인별 생존 확률을 계산하는 로지스틱 회귀모델을 제작하였다.

- 남성의 전체 생존률이 여성보다 높아 WCF라는 통념만으로 실제 결과를 설명하기 어려웠다.
- 승무원은 승객보다 생존률이 높았고 Crew는 Survival과 약 +0.14로 최종 개인 factor 중 가장 큰 양의 상관을 보였다.
- Age와 Companionship 등 다른 factor의 단순 상관은 약했으며, 한 가지 정보만으로 생존을 판단하기 어렵다.
- 최종 모델 정확도는 약 61.9%였고, 새로운 승객 정보에 대해 생존 확률을 출력하는 기능을 구현하였다.

2. 연구의 한계와 후속 연구

자료가 서로 다른 시대와 사고를 합친 역사 자료라는 점, 결측값을 중앙값·최빈값으로 보완했다는 점, 최종 모델에 네 가지 factor만 사용했다는 점이 한계이다. 후속 연구에서는 사고 당시 위치, 구명조끼 착용, 대피 경로, 부상, 사고 유형, 수온·날씨, 구조까지 걸린 시간 등 상황 변수를 추가할 수 있다. 또한 사고 단위로 학습자료와 평가자료를 나누어 새로운 사고에서도 성능이 유지되는지 검증하고, 정확도 외에 혼동행렬·재현율·ROC-AUC 같은 지표를 함께 확인하면 좋다.

※ 참고문헌

1. Elinder, M., & Erixson, O. (2012). Gender, social norms, and survival in maritime disasters.
2. European Commission / European Parliament. Road death statistics in the EU (2024 data).
3. Eurostat. Maritime accident fatalities in the EU (tran_sf_marv, 2024).
4. EASA. Annual Safety Review 2025 (European commercial air transport, 2024).

※ 참고문헌은 첨부된 작품설명서에 제시된 논문 및 자료를 기준으로 정리하였다.